Arbres de décision

Arbres de décision

Algorithmes ID3 et CART

Random Forests

Objectif du chapitre

- Comprendre les arbres de décisions
- Construire un arbre de décision
- Connaitre les différents algorithmes d’arbres de décision

Plan

- Arbres de décisions
- Algorithme ID3
- Algorithme CART

Arbres de décisions

Définitions

- Utilisés dans l'exploration de données et en informatique décisionnelle.
- Ils emploient une représentation hiérarchique de la structure des données sous forme des séquences de décisions (tests) en vue de la prédiction d'un résultat ou d'une classe.
- Les arbres de décision sont des classifieurs pour des instances (individus) représentées dans un formalisme attribut/valeur (variable/valeur)
- Les nœuds de l'arbre testent les attributs (les nœuds représenta les variables)
- Il y a une branche pour chaque valeur de l'attribut testé
- Les feuilles spécifient les classes (deux ou plus)

Définitions

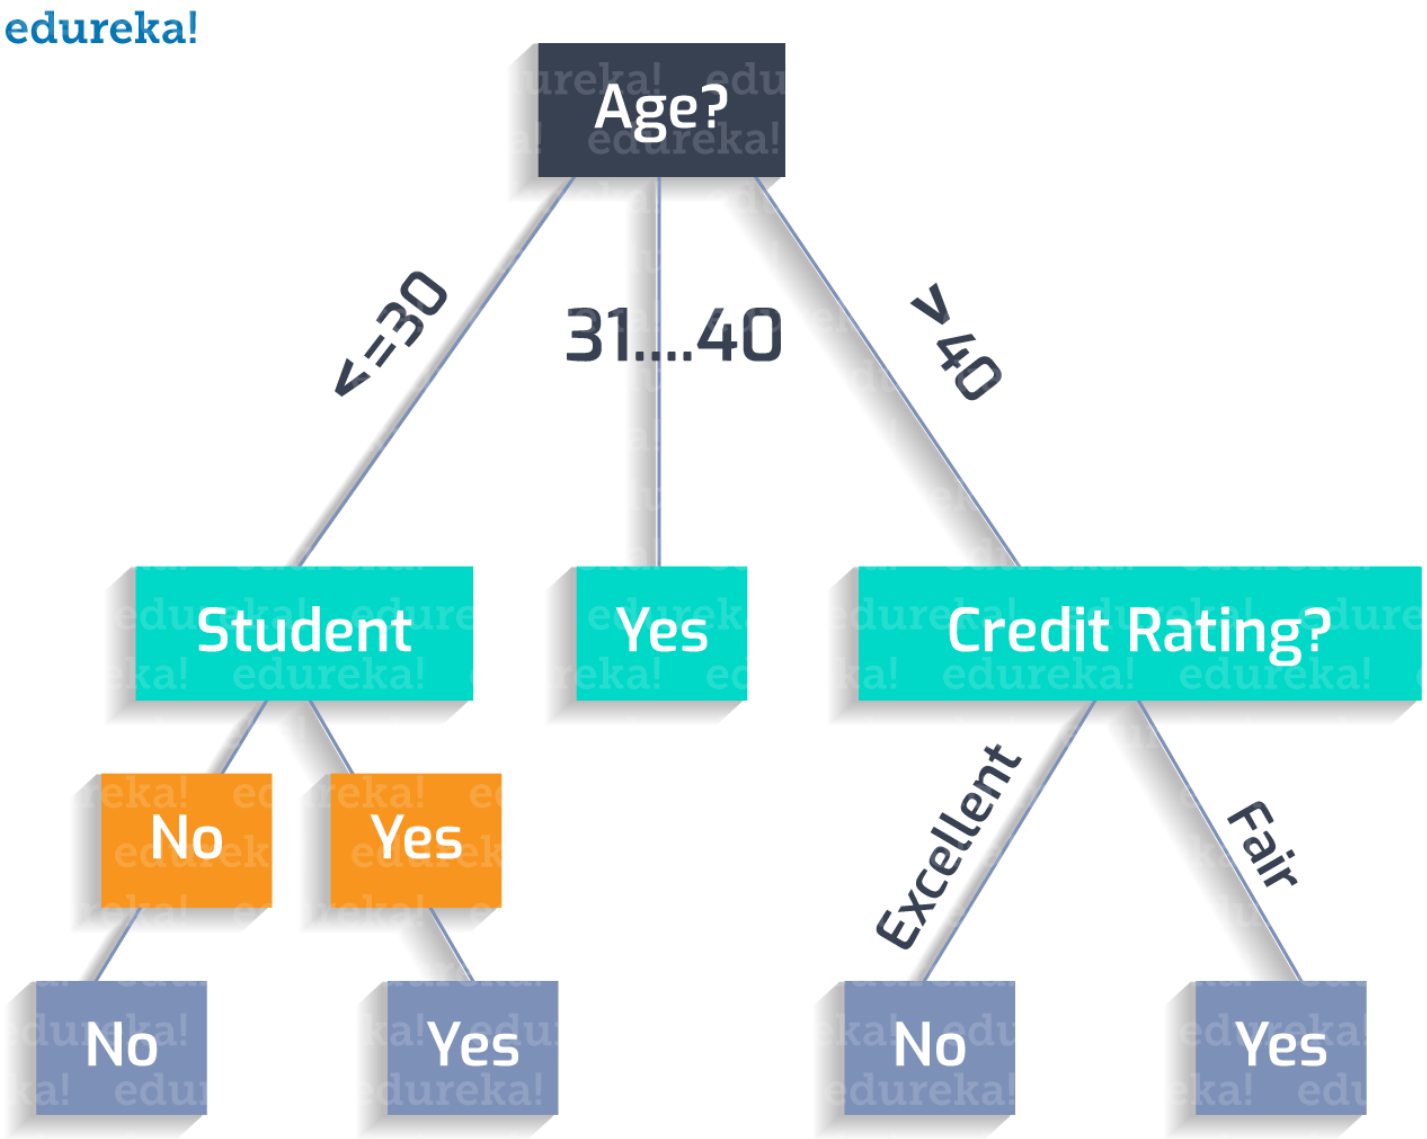

Définitions

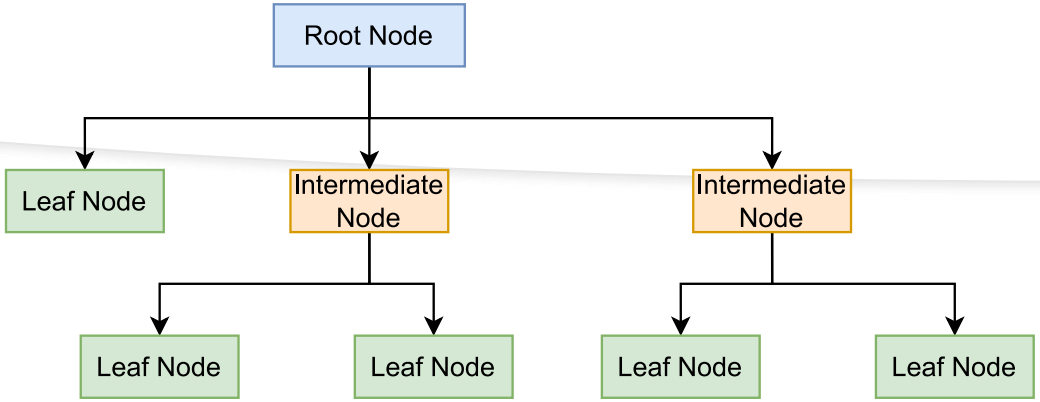

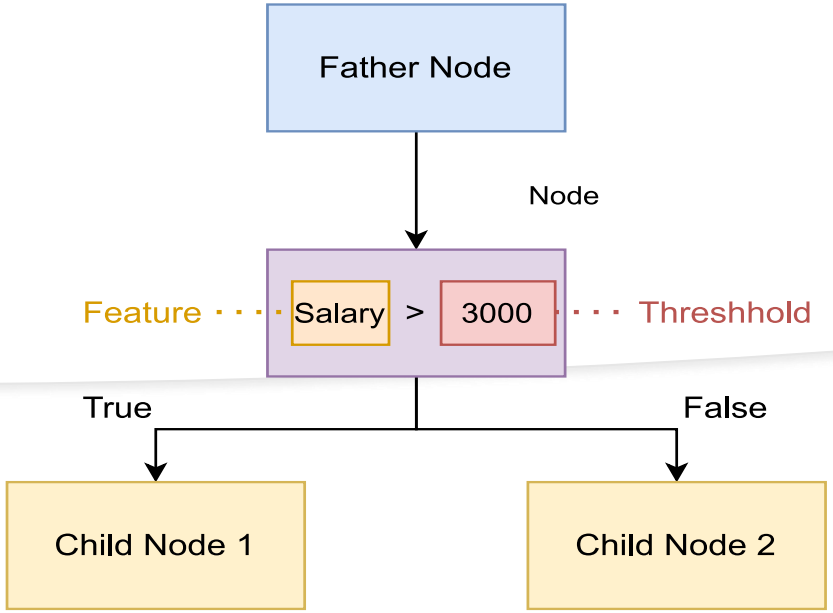

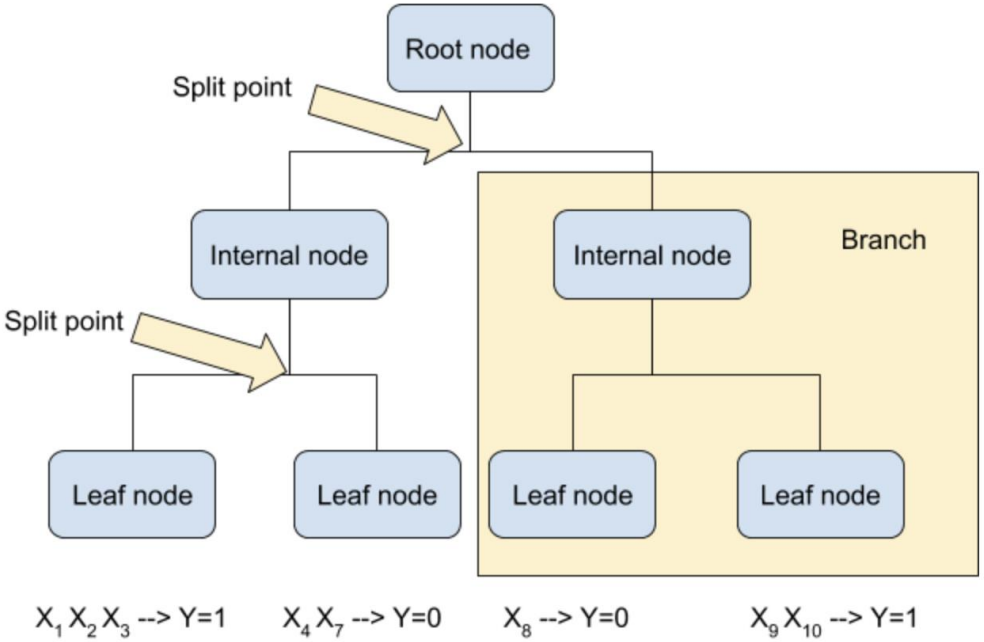

Algorithmes

- ID3 (Iterative Dichotomiser 3): développé en 1986 par Ross Quinlan. Il peut être appliqué seulement sur les caractéristiques nominales. Il est utilisé pour le classement.

- C4.5: une extension de ID3 par Ross Quinlan. Il peut être appliqué sur tous les types de caractéristiques. Il est utilisé pour le classement.

- C5.0: une extension commerciale de C4.5, toujours par Ross Quinlan.

- CART (Classification and Regression Trees): comme C4.5 mais utilise d'autres métriques. Aussi, l'algorithme supporte la régression.

Construction d’un arbre de décision

- L'algorithme général de création d'un arbre de décision:
  - Déterminer la meilleure caractéristique (attribut) dans l'ensemble de données d'entrainement.
  - Diviser les données d'entrainement en sous-ensembles contenant les valeurs possibles de la meilleure caractéristique.
  - Générez de manière récursive de nouveaux arbres de décision en utilisant les sous-ensembles de données créés.
  - Lorsqu'on ne peut plus classifier les données, on s'arrête.

Algorithme ID3

Sélectionner la meilleure caractéristique (ID3)

- Etant donnée un ensemble de classes K,
- Entropie: $E(S) = -\sum_{i=1}^{K} p_i \log_2(pi)$

- Ou (en divisant le nombre des échantillons d'une certaine classe sur le nombre de tous les échantillons dans les données d'entrainement) :

$$p_i = \frac{|i|}{|S|}$$

Remarques:

$$0 \leq E(S) \leq 1$$

$$\log_2(x) = \frac{\log(x)}{\log(2)}$$

Sélectionner la meilleure caractéristique (ID3)

Le gain d'information:

$$Gain(S, attribut) = E(S) - \sum_{i=1}^{K} p_i \, E(S_i)$$

La caractéristiques ayant le plus de gain d'information est celle sélectionnée comme meilleure,

La valeur avec entropie nulle est considérée comme feuille de l'arbre

Exemple ID3

ID	Sexe	Age	Etat civil	Revenu	Achat
1	Homme	18 - 35	Marié	Moyen	Non
2	Homme	<18	Célibataire	Faible	Non
3	Homme	> 35	Marié	Élevé	Oui
4	Femme	<18	Célibataire	Moyen	Non
5	Homme	18 - 35	Célibataire	Moyen	Non
6	Femme	18 - 35	Célibataire	Élevé	Oui
7	Femme	18 - 35	Marié	Faible	Non
8	Homme	18 - 35	Marié	Élevé	Oui
9	Homme	> 35	Célibataire	Faible	Oui
10	Femme	<18	Célibataire	Moyen	Non
11	Femme	> 35	Célibataire	Moyen	Oui
12	Femme	> 35	Marié	Élevé	Oui
13	Homme	18 - 35	Célibataire	Faible	Non
14	Femme	18 - 35	Marié	Moyen	Oui

- Construisez l'arbre de décision résultant de ces exemples en utilisant l'algorithme ID3.
- Exprimez la classe des exemples positifs sous la forme d'un prédicat logique.
- Décrivez comment un nouvel exemple est classifie dans un arbre de décision entraine.

Exemple ID3 : Solution

Au total on a 14 échantillons: 7 Oui et 7 Non:

$$E(S) = -\sum_{i=1}^{K} p_i \log_2(p_i)$$

$$E(S) = -\left(\left[\frac{7}{14}\log_2\frac{7}{14}\right] + \left[\frac{7}{14}\log_2\frac{7}{14}\right]\right) = -\left[\frac{7}{14}\log_2\frac{7}{14}\right] - \left[\frac{7}{14}\log_2\frac{7}{14}\right] = 1$$

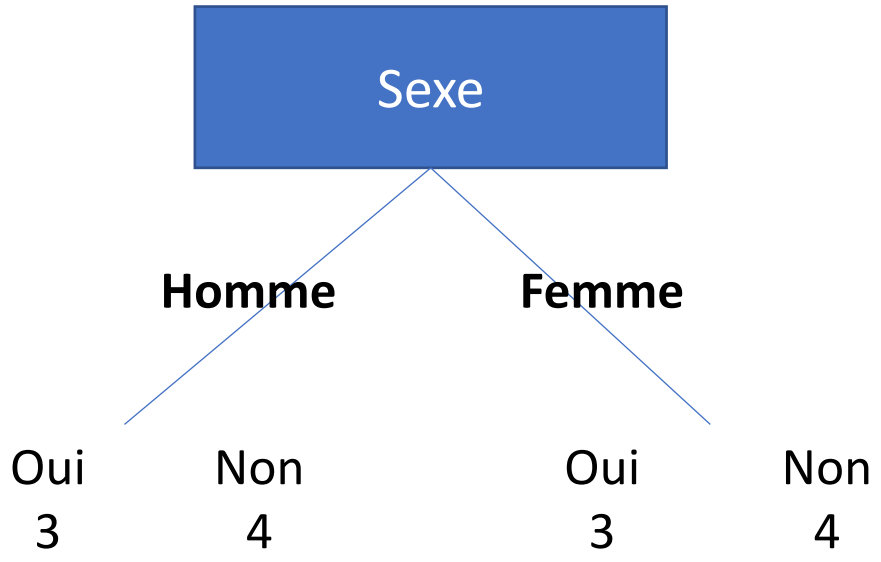

$$E(Homme) = -\sum_{i=1}^{K} p_i \log_2(p_i)$$

$$E(Homme) = -\left[\frac{3}{7}\log_2\frac{3}{7}\right] - \left[\frac{4}{7}\log_2\frac{4}{7}\right] = 0{,}985$$

$$E(Femme) = -\left[\frac{4}{7}\log_2\frac{4}{7}\right] - \left[\frac{3}{7}\log_2\frac{3}{7}\right] = 0{,}985$$

Exemple ID3 : Solution

$$Gain(S, sexe) = E(S) - \sum_{i=1}^{K} p_i E(S_i) = 1 - \left[\frac{7}{14} \times 0{,}985\right] - \left[\frac{7}{14} \times 0{,}985\right] = 0{,}015$$

De la même manière, on calcule les autres gains d'entropie pour les attributs restants

Attribut	Gain	
Sexe	$1 - [(7/14)(0.985) + (7/14)(0.985)]$	= 0.015
Age	$1 - [(3/14)(0) + (7/14)(0.985) + (4/14)(0)]1$	=0.507
État civil	$1 - [(8/14)(0.954) + (6/14)(0.918)]$	=0.061
Revenu	$1 - [(4/14)(0.811) + (6/14)(0.918) + (4/14)(0)]$	=0.375

On peut voir que l'attribut avec le plus grand gain d'entropie est l'attribut **Age**

Ainsi, on choisi l'attribut Age afin de faire la première séparation

Exemple ID3 : Solution

- Le nœud Age <18 est pur
- Le nœud Age >35 est aussi pur
- Ils n'ont pas besoin d'être subdiviser

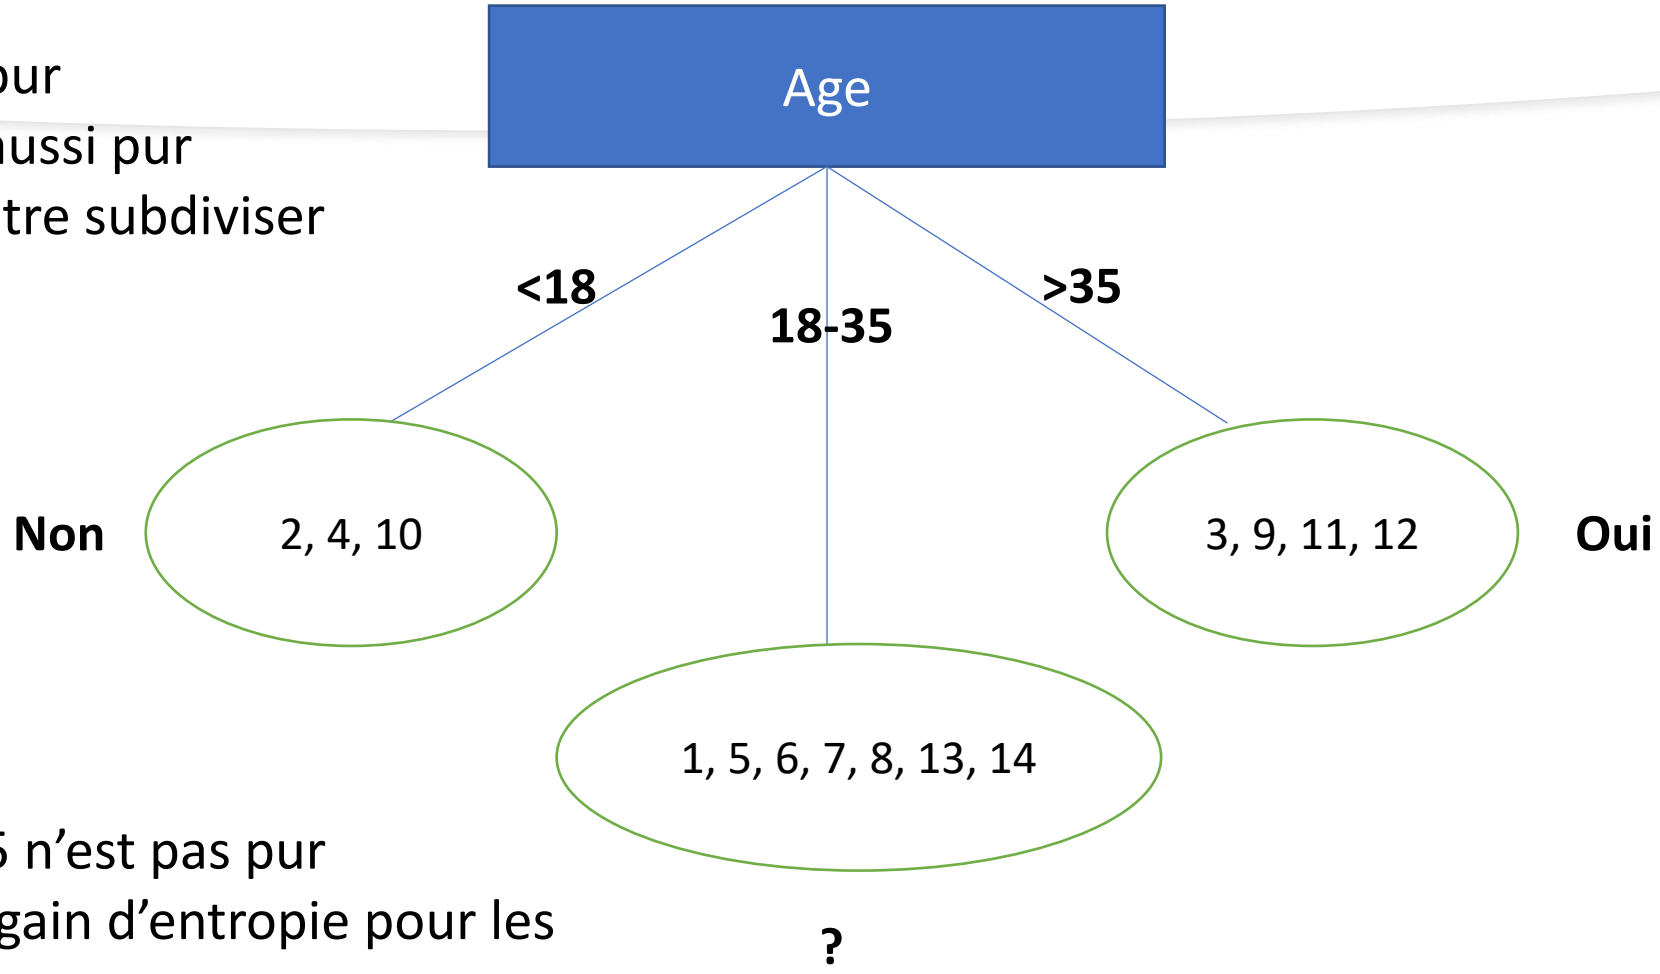

- Le nœud Age = 38 – 35 n'est pas pur
- Nous devons tester le gain d'entropie pour les attributs restants

Exemple ID3 : Solution

ID	Sexe	Age	Etat civil	Revenu	Achat
1	Homme	18 - 35	Marié	Moyen	Non
5	Homme	18 - 35	Célibataire	Moyen	Non
6	Femme	18 - 35	Célibataire	Elevé	Oui
7	Femme	18 - 35	Marié	Faible	Non
8	Homme	18 - 35	Marié	Elevé	Oui
13	Homme	18 - 35	Célibataire	Faible	Non
14	Femme	18 - 35	Marié	Moyen	Oui

Exemple ID3 : Solution

Au total on a 7 échantillons: 3 Oui et 4 Non:

$$E(S) = -\sum_{i=1}^{K} p_i \log_2(p_i)$$

$$E(S) = -\left(\left[\frac{3}{7}\log_2\frac{3}{7}\right] + \left[\frac{4}{7}\log_2\frac{4}{7}\right]\right) = -\left[\frac{3}{7}\log_2\frac{3}{7}\right] - \left[\frac{4}{7}\log_2\frac{4}{7}\right] = 0{,}985$$

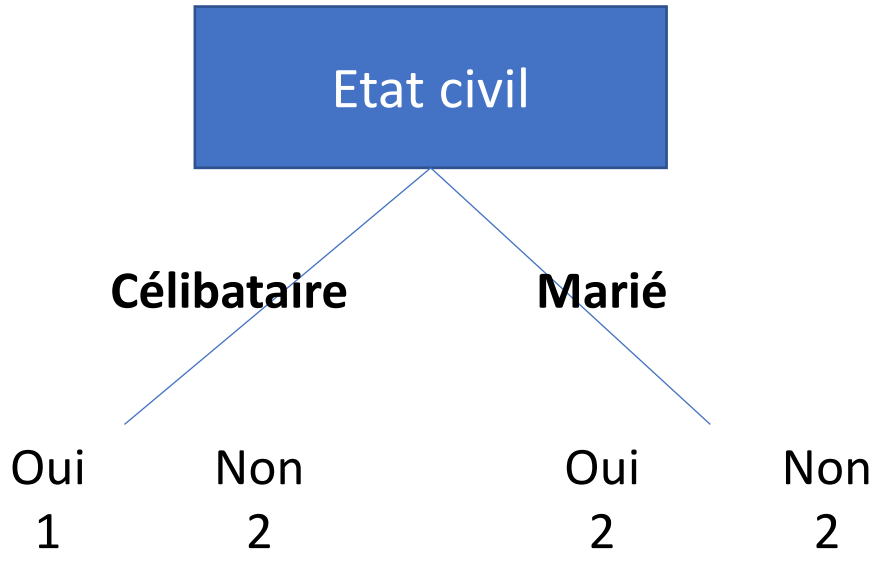

$$E(Célibataire) = -\sum_{i=1}^{K} p_i \log_2(p_i)$$

$$E(Célibataire) = -\left[\frac{1}{3}\log_2\frac{1}{3}\right] - \left[\frac{2}{3}\log_2\frac{2}{3}\right] = 0{,}918$$

$$E(Marié) = -\left[\frac{2}{4}\log_2\frac{2}{4}\right] - \left[\frac{2}{4}\log_2\frac{2}{4}\right] = 1$$

Exemple ID3 : Solution

$$Gain(S_{age=18-35}, etat\ civil) = E(S) - \sum_{i=1}^{K} p_i E(S_i) = 0{,}985 - \left[\frac{3}{7} \times 0{,}918\right] - \left[\frac{4}{7} \times 1\right] = 0{,}020$$

De la même manière, on calcule les autres gains d'entropie pour les attributs restants

Attribut	Gain	
Sexe	$0.985 - [(4/7)(0.811) + (3/7)(0.918)]$	= 0.128
État civil	$0.985 - [(3/7)(0.918) + (4/7)(1)]$	= 0.02
Revenu	$0.985 - [(2/7)(0) + (3/7)(0.918) + (2/7)(0)]$	= 0.592

On peut voir que l'attribut avec le plus grand gain d'entropie est l'attribut **Revenu**

Ainsi, on choisi l'attribut Revenu afin de faire la première séparation

Exemple ID3 : Solution

- Le nœud Revenu = Faible est pur
- Le nœud Revenu = Elevé est pur
- Ils n'ont pas besoin d'être subdiviser

- Le nœud Revenu = Moyen n'est pas pur
- On peut encore subdiviser

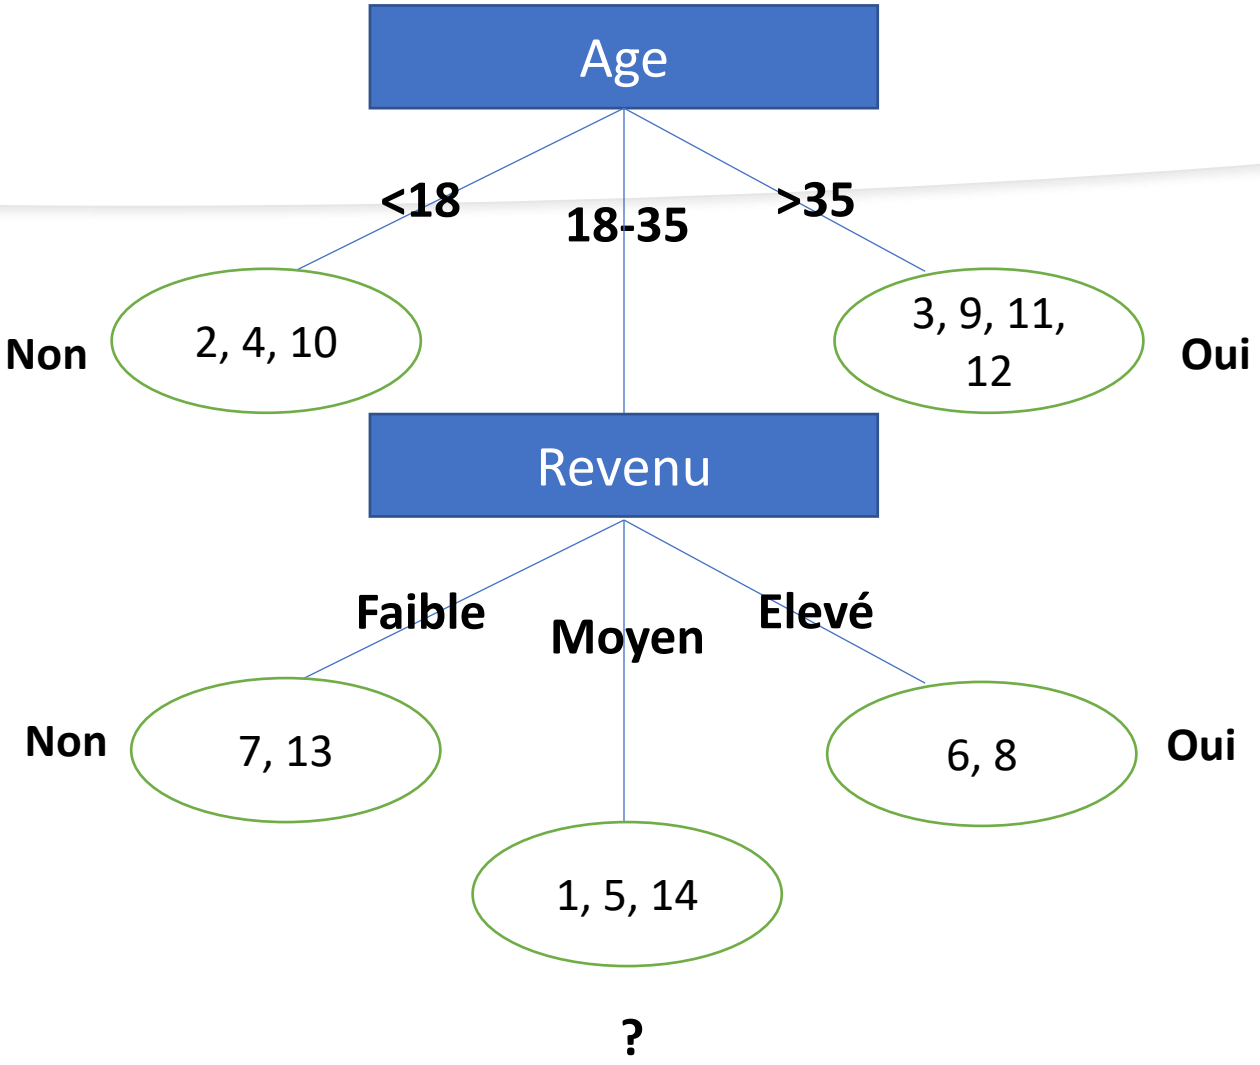

Exemple ID3 : Solution

Attribut	Gain	
Sexe	$0.918 - [(2/3)(0) + (1/3)(0)]$	=0.918
Etat civil	$0.918 - [(1/3)(0) + (2/3)(1)]$	=0.252

L'attribut **Sexe** donne le meilleur gain d'entropie**, O**n le choisi pour séparer les exemples

Exemple ID3 : Solution

Tous les nœuds résultants sont purs, On s'arrête

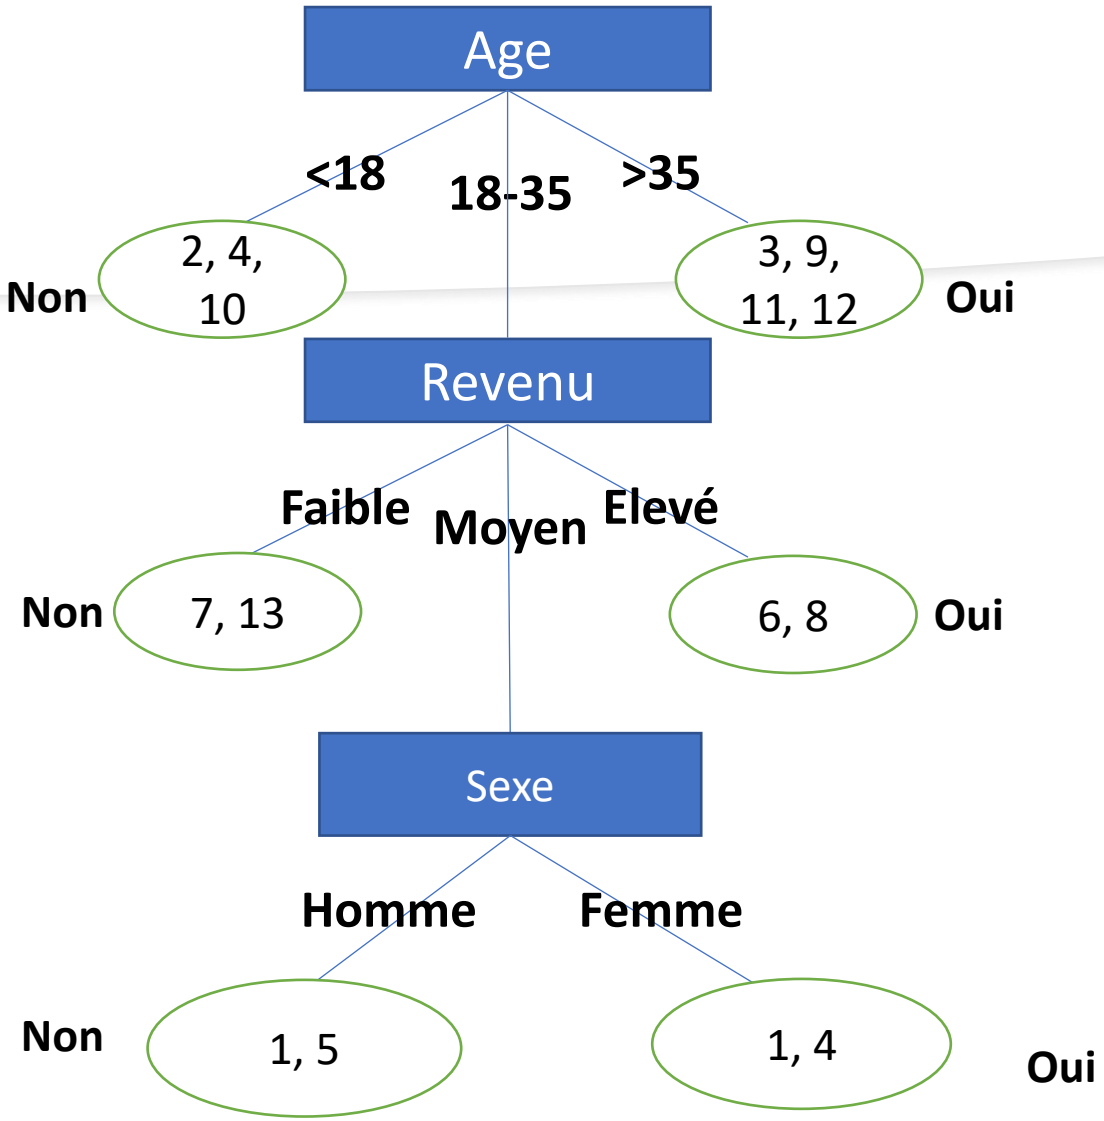

Pour exprimer la classe des acheteurs potentiels, on identifie tous les chemins depuis la racine de l'arbre jusqu'a une feuille de l'arbre contenant des exemples positifs.

La classe des exemples positifs s'exprime ensuite comme une disjonction (OU - V) de conjonctions (ETA) pour chaque chemin:

AchatOui(x) <= (Age(x)>35) V (Age(x)∈ [18-35] A Revenu(x) = Élevé) V (Age(x)∈ [18-35] A Revenu(x) = Moyen A Sexe = Femme).

Exemple ID3 : Solution

- Pour classifier un nouvel exemple, on traverse l'arbre depuis la racine jusqu'a une feuille.
- Pour chaque nœud interne rencontré, on emprunte la branche correspondant au résultat du test de ce nœud.
- Une fois dans la feuille, on assigne l'exemple a la classe la plus fréquente des exemples d'entrainement contenus dans cette feuille.

C4.5 (Iterative Dichotomiser 4.5)

- Élagage après la construction de l’arbre : C4.5 utilise une procédure qui permet transformer en feuilles des sous-arbres qui ne contribuent à un meilleur résultat (score « accuracy ») de l’apprentissage.

- Limitation de la profondeur de l’arbre par la taille minimale du nœuds (paramètre de construction).

- Chaque attribut peut avoir un poids (coût).

- Traitement des variables continues en cherchant des seuils qui maximisent le gain d’information (découpage binaire).

- Traitement des valeurs manquantes.

C5.0 (Iterative Dichotomiser 5.0)

- Version commerciale.
- Vitesse et utilisation mémoire.
- Optimisé pour des bases de données de très grande taille.
- Arbres plus petits.
- Pondération des cas et erreurs de classement.